Sistemas Operacionais

Busca Paralela em Arquivos com Multithreading

Abrahão Picanço e Lucas Gabriel

Introdução

- **O que é busca paralela em arquivos?**
  - Técnica para procurar dados em múltiplos arquivos simultaneamente.
  - Usa multithreading para dividir o trabalho entre várias threads.
- **Por que é importante?**
  - Acelera o processamento em grandes volumes de dados.
  - Aproveita arquiteturas multicore modernas.

O que é Multithreading?

Definição

Multithreading é a capacidade de um programa executar múltiplas threads (linhas de execução) simultaneamente, cada uma realizando uma tarefa específica.

- **Vantagens**:
  - Melhor utilização de CPUs multicore.
  - Redução do tempo de execução para tarefas paralelizáveis.
- **Aplicação na busca em arquivos:**
  - Cada thread processa um arquivo ou uma parte de um arquivo.

Como Funciona a Busca Paralela?

1. **Divisão da tarefa:**
   - Lista de arquivos é dividida entre threads.
   - Cada thread busca uma palavra-chave ou padrão em seu subconjunto.
2. **Execução concorrente:**
   - Threads leem e processam arquivos simultaneamente.
3. **Agregação de resultados:**
   - Resultados de cada thread são combinados para formar a saída final.

Vantagens da Busca Paralela

- **Eficiência**: Reduz significativamente o tempo de busca em grandes conjuntos de dados.
- **Escalabilidade**: Pode ser aplicada a milhares de arquivos ou grandes diretórios.
- **Aproveitamento de hardware**: Utiliza múltiplos núcleos de CPU.
- **Flexibilidade:** Pode ser adaptada para diferentes tipos de busca (ex.: regex, case-sensitive).

Exemplo Prático

Cenário

Buscar uma palavra em múltiplos arquivos de texto usando threads.

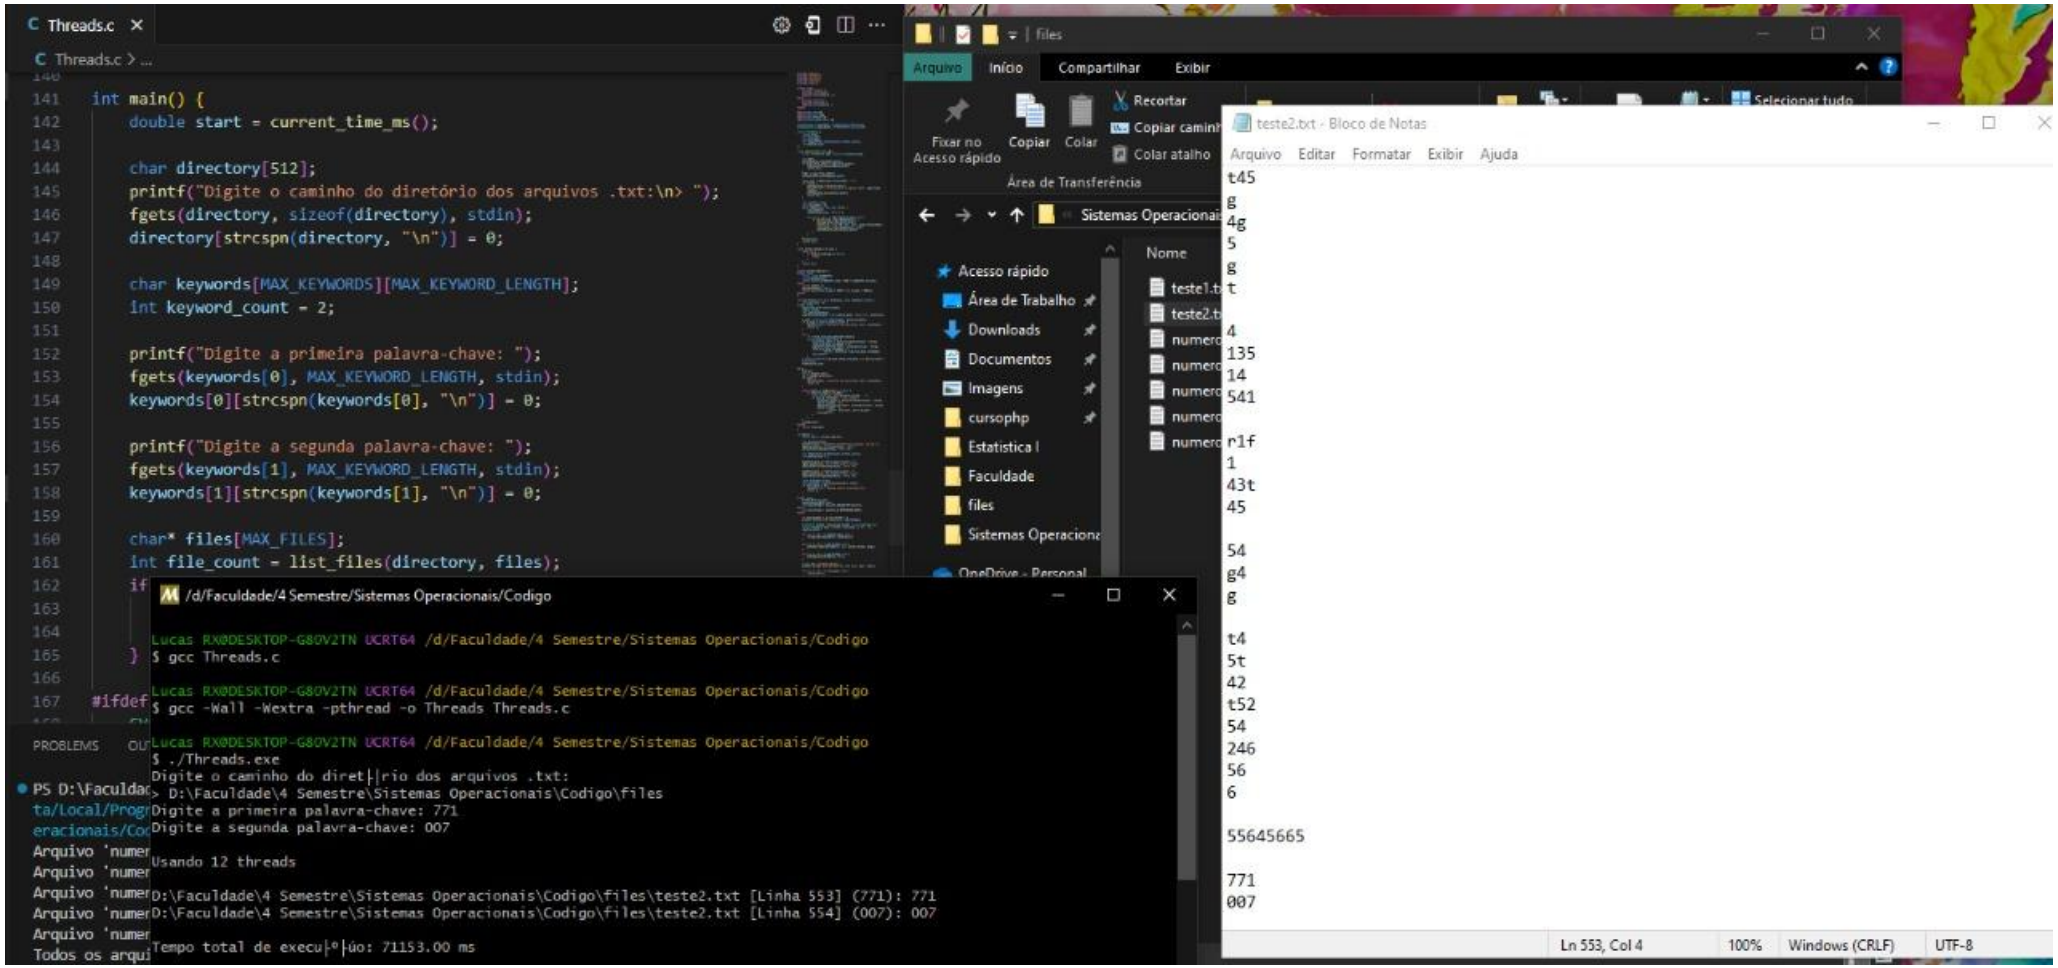

Exemplo Prático

Cenário

Buscar uma palavra em múltiplos arquivos de texto usando threads.

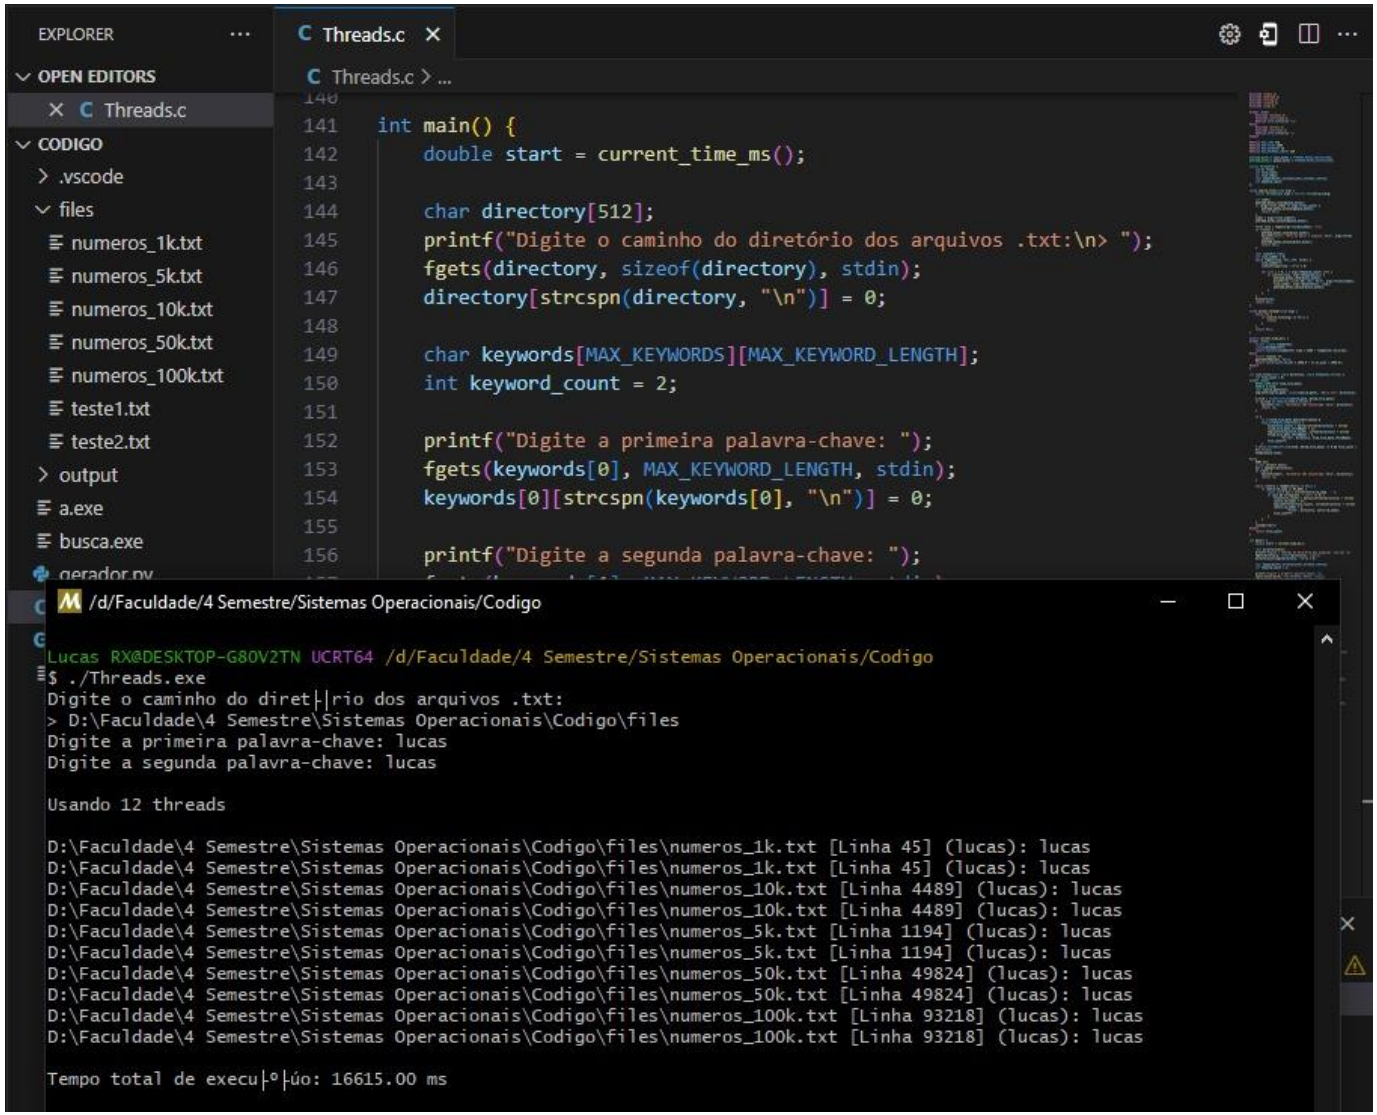

Desafios e Cuidados

- **Concorrência:**
  - Gerenciamento de acesso a recursos compartilhados (ex.: lista de resultados).
  - Uso de mecanismos como Lock para evitar condições de corrida.
- **Erros de I/O:**
  - Arquivos corrompidos ou inacessíveis podem causar falhas.
- **Overhead:**
  - Criar e gerenciar threads tem um custo computacional. Muitas threads podem saturar o sistema.

Aplicações Reais

- **Logs de servidores:** Busca rápida por erros ou eventos específicos em logs.
- **Motores de busca:** Indexação paralela de documentos.
- **Análise de dados:** Processamento de grandes conjuntos de dados textuais.
- **Ferramentas de desenvolvimento:** Busca em código-fonte (ex.: IDEs).

Conclusão

- A busca paralela com multithreading é uma técnica poderosa para acelerar o processamento de arquivos.
- Combina eficiência, escalabilidade e aproveitamento de hardware moderno.
- Requer cuidado com concorrência e gerenciamento de recursos.
- Aplicável em diversas áreas, desde análise de dados até ferramentas de software.